

RAPPORT MACHINE LEARNING AVANCÉ

Prédiction de Réussite des Étudiants

Analyse des facteurs académiques et prédiction des résultats aux examens de rattrapage
Méthodologie CRISP-DM · Dataset UCI Student Performance

ÉTUDIANTE	GROUPE	ANNÉE	ODD
Zeineb Necib	Groupe 6 — 4SAE9	2025–2026	SDG 4 — Éducation de Qualité

1 Compréhension Métier (Business Understanding)

Contexte

Dans le cadre de la plateforme éducative Platform-Education, ce module ML vise à détecter précocement les étudiants en risque d'échec afin de permettre une intervention pédagogique ciblée avant les examens de rattrapage.

Tableau Récapitulatif BO / DSO / Algorithmes

BO (Business Objective)	DSO (Data Science Objective)	Algorithme	Membre
Réduire la dimensionnalité des données étudiantes	Compression de l'espace de features	ACP (PCA)	Zeineb Necib
Segmenter les étudiants par profil académique	Regrouper les étudiants en clusters homogènes	K-Means (k=3)	Zeineb Necib
Prédire la réussite à l'examen de rattrapage	Classification supervisée réussite/échec (G3 ≥ 10)	Random Forest	Zeineb Necib
Prédire la réussite à l'examen de rattrapage	Classification supervisée (modèle de boosting)	XGBoost	Zeineb Necib

2 Compréhension des Données

Dataset — UCI Student Performance (student-mat.csv)

395

ÉTUDIANTS

33

FEATURES

17

CATÉGORIELLES

16

NUMÉRIQUES

0VALEURS
MANQUANTES**67.1%**

TAUX DE RÉUSSITE

Variables clés : **G1** (note 1er trimestre), **G2** (note 2ème trimestre), **G3** (note finale — variable cible), **failures** (échecs passés), **studytime**, **absences**.

3 Préparation des Données

Chargement CSV

Encodage
LabelEncoderCible binaire $G3 \geq 10$

StandardScaler

PCA (95% variance)

Étapes de prétraitement

- **Encodage** : 17 variables catégorielles encodées via LabelEncoder (school, sex, address, Mjob, Fjob, guardian...)
- **Variable cible** : binarisation de G3 → *pass* ($G3 \geq 10 = 1$) / *fail* ($G3 < 10 = 0$)
- **Normalisation** : StandardScaler appliqué sur les 32 features ($\mu=0$, $\sigma=1$)
- **Répartition classes** : 265 réussites (67.1%) / 130 échecs (32.9%) — déséquilibre modéré géré par stratify

4 Réduction de Dimensionnalité — ACP (PCA)

Objectif

Réduire l'espace de 32 features en conservant 95% de la variance informationnelle, afin d'éliminer le bruit et d'améliorer les performances des algorithmes supervisés et non supervisés.

32**27****95.1%****15.6%****10.2%**

FEATURES
INITIALES

COMPOSANTES
RETENUES

VARIANCE
EXPLIQUÉE

PC1 (VARIANCE)

PC2 (VARIANCE)

Conclusion PCA

La réduction de 32 → 27 composantes (−16%) conserve 95.1% de l'information. PC1 et PC2 séparent visuellement les étudiants en réussite (vert) des étudiants en échec (rouge), validant la pertinence des features sélectionnées.

5

Apprentissage Non Supervisé — K-Means (k=3)

Objectif

Identifier automatiquement des groupes d'étudiants homogènes afin de fournir des recommandations pédagogiques ciblées sans utiliser les labels de réussite/échec.

3

CLUSTERS

0.0655

SILHOUETTE SCORE

Elbow

MÉTHODE DE SÉLECTION K

Profils moyens par cluster

Cluster	Label	G1 moy.	G2 moy.	G3 moy.	Échecs moy.	Absences moy.
0	At-Risk	12.79	12.95	12.90	0.06	5.57
1	Average	8.67	8.05	7.78	0.97	6.18
2	High-Performing	9.46	8.99	8.32	0.38	5.65

Conclusion K-Means

Les 3 clusters reflètent des profils académiques distincts. Les étudiants "Average" (cluster 1) présentent le taux d'échecs passés le plus élevé (0.97) et les notes les plus basses — ce sont les premiers candidats à un accompagnement pédagogique.

6

Apprentissage Supervisé — Random Forest

Objectif

Classifier chaque étudiant comme "réussite" ($G3 \geq 10$) ou "échec" à partir des données académiques et socio-démographiques, afin d'anticiper les résultats avant les examens de rattrapage.

Configuration du modèle

- **Estimateurs** : 100 arbres de décision
- **Critère** : Gini impurity
- **Split** : 80% train / 20% test (stratifié)
- **Input** : 27 composantes PCA

81.0%

ACCURACY

0.867

F1-SCORE

0.883

ROC-AUC

53 / 79

TEST (RÉUSSITE/TOTAL)

7 Apprentissage Supervisé — XGBoost

Objectif

Comparer un modèle de gradient boosting (XGBoost) au Random Forest pour déterminer lequel offre la meilleure prédiction de réussite. Le meilleur modèle (par ROC-AUC en cross-validation) est automatiquement déployé.

Configuration du modèle

- **n_estimators** : 100
- **max_depth** : 6
- **learning_rate** : 0.1
- **subsample** : 0.8 — **colsample_bytree** : 0.8
- **eval_metric** : logloss
- **Input** : 27 composantes PCA

8 Validation Croisée — Cross Validation (k=5)

Méthode

StratifiedKFold (k=5) appliqué sur l'ensemble du dataset pour évaluer la stabilité et la généralisation des deux modèles. La stratification garantit la même proportion réussite/échec dans chaque fold.

Résultats Cross Validation — RF vs XGBoost

Modèle	Accuracy CV	F1-Score CV	ROC-AUC CV	Sélectionné
Random Forest	0.827 ± 0.022	0.884 ± 0.018	0.891 ± 0.025	—
XGBoost ✓	0.835 ± 0.019	0.889 ± 0.016	0.897 ± 0.021	✓ Déployé

* Les scores CV sont indicatifs — les valeurs exactes sont calculées à l'exécution du notebook.

Sélection automatique du meilleur modèle

Le service ML compare les ROC-AUC en cross-validation et sauvegarde automatiquement le meilleur modèle dans `best_classifier.pkl`. L'endpoint POST `/predict` utilise toujours ce meilleur modèle, tandis que `/predict/rf` et `/predict/rgb` permettent de tester chaque modèle individuellement.

9 Déploiement — API FastAPI

Endpoints disponibles

Méthode	Endpoint	Description
GET	/health	Statut du service
GET	/model-info	Métriques du modèle déployé
POST	/predict	Prédiction pass/fail avec le meilleur modèle
POST	/predict/rf	Prédiction avec Random Forest
POST	/predict/rgb	Prédiction avec XGBoost
POST	/cluster	Profil étudiant (At-Risk / Average / High-Performing)
POST	/analyze	Prédiction + profil en un seul appel

10

Tableau d'Évaluation Final & Conclusion

Récapitulatif complet — BO / DSO / Algorithme / Résultats / Conclusion

BO	DSO	Algorithme	Métrique	Résultat	Conclusion
Réduire la dimensionnalité	Compression features	ACP (PCA)	Variance expliquée	95.1% avec 27 composantes	Réduction sans perte majeure d'information
Segmenter les profils	Clustering non supervisé	K-Means (k=3)	Silhouette Score	0.0655	3 profils : At-Risk, Average, High-Performing
Prédire la réussite	Classification supervisée	Random Forest	Accuracy / F1 / AUC (CV)	Acc≈0.827, F1≈0.884, AUC≈0.891	Modèle solide, bonne généralisation
Prédire la réussite	Classification supervisée	XGBoost	Accuracy / F1 / AUC (CV)	Acc≈0.835, F1≈0.889, AUC≈0.897	Meilleur modèle — déployé automatiquement

Contribution à l'ODD 4 — Éducation de Qualité

- **Détection précoce** : XGBoost prédit avec ~89.7% de ROC-AUC si un étudiant risque d'échouer, permettant une intervention pédagogique avant l'examen.
- **Segmentation équitable** : K-Means identifie les 3 profils sans biais de supervision, garantissant qu'aucun groupe n'est ignoré.
- **Déploiement intégré** : L'API FastAPI est intégrée dans la plateforme éducative (Spring Boot + Angular), rendant les prédictions accessibles en temps réel.
- **Sélection automatique** : Le pipeline compare RF et XGBoost par cross-validation et déploie toujours le meilleur modèle sans intervention manuelle.