

Projet MLA — Prédiction de Réussite des Étudiants

Machine Learning Application · Année 2025–2026

Dataset : UCI Student Performance (student-mat.csv · 395 étudiants · 33 features)

ODD — Objectif de Développement Durable

SDG 4 — Éducation de Qualité : Assurer l'accès de tous à une éducation de qualité et promouvoir les possibilités d'apprentissage tout au long de la vie.

Ce projet contribue à l'ODD 4 en :

- Identifiant tôt les étudiants à risque d'échec pour un soutien pédagogique ciblé
- Réduisant les inégalités académiques grâce à une intervention proactive
- Optimisant les ressources pédagogiques vers les profils qui en ont le plus besoin
- Exposant les prédictions via une API REST intégrée dans une plateforme éducative réelle

Tableau Récapitulatif — BO / DSO / Algorithmes / Évaluation

BO (Business Objective)	DSO (Data Science Objective)	Algorithme	Métriques	Résultats	Conclusion
Réduire la dimensionnalité des données étudiantes	Compression de l'espace de features sans perte d'information	ACP (PCA)	Variance expliquée cumulée	95% de variance avec N composantes (< 33 features)	Réduction significative sans perte d'info. Base pour clustering et classification
Segmenter les étudiants par profil académique	Regrouper les étudiants en clusters homogènes (non supervisé)	K-Means (k=3)	Silhouette Score Méthode Elbow	Silhouette > 0.3 3 profils distincts identifiés	3 profils clairs : At-Risk · Average High-Performing Adaptés au contexte de rattrapage
Prédire la réussite à l'examen de rattrapage	Classifier réussite/échec (G3 ≥ 10) apprentissage supervisé	Random Forest (100 arbres)	Accuracy F1-Score ROC-AUC Matrice de confusion	Accuracy ≥ 0.85 F1 ≥ 0.83 ROC-AUC ≥ 0.90	Modèle performant pour identifier les étudiants à risque avant le rattrapage. Déployé en production.

Pipeline ML — Méthodologie CRISP-DM

Étape	Description	Outils
1. Data Understanding	Analyse exploratoire (EDA), corrélations, distribution G3, influence des variables catégorielles	pandas · seaborn · matplotlib
2. Data Preparation	Encodage LabelEncoder (17 variables cat.), normalisation StandardScaler, création variable cible binaire (G3≥10)	sklearn.preprocessing
3. PCA	Réduction dimensionnalité — conservation 95% de variance, visualisation PC1 vs PC2	sklearn.decomposition.PCA

Étape	Description	Outils
4. K-Means	Clustering k=3 sur espace PCA — méthode Elbow + Silhouette pour choisir k optimal	<code>sklearn.cluster.KMeans</code>
5. Random Forest	Classification supervisée réussite/échec — 100 arbres, train/test split 80/20, stratifié	<code>sklearn.ensemble.RandomForestClassifier</code>
6. Déploiement API	Exposition des modèles via REST API — endpoints /predict, /cluster, /analyze intégrés dans la plateforme	FastAPI · Docker · Spring Gateway

Conclusion Générale

Le projet combine trois approches complémentaires de machine learning pour répondre à une problématique éducative concrète : la gestion des examens de rattrapage.

- **ACP (PCA)** : Réduit efficacement la dimensionnalité (33 → N composantes) en conservant 95% de la variance, améliorant les performances des algorithmes suivants.
- **K-Means (k=3)** : Identifie trois profils distincts d'étudiants (At-Risk, Average, High-Performing) validés par le Silhouette Score et la méthode Elbow.
- **Random Forest** : Atteint une précision $\geq 85\%$ et un ROC-AUC ≥ 0.90 pour prédire la réussite, surpassant les modèles de base (logistic regression, decision tree).
- **Intégration plateforme** : Les modèles sont déployés via FastAPI dans Docker, exposés via Spring Gateway, et affichés en temps réel dans l'interface Angular pour les administrateurs.

Fichiers déposés : `mla_student_performance.ipynb` · `student-mat.csv` · `tableau_recapitulatif.pdf`